# Hackathon - Carreiras de TI - Curitiba/PR

## Contexto:

- Dataset contendo dados de qualidade do ar do Centro de monitoramento municipal do meio ambiente de Beijing, de março de 2013 à fevereiro de 2017.
- PM2.5 se refere a particulas atmosféricas que possuem diâmetro menor que 2.5 micrômetros, é uma medida de poluição.

## 1. Identificação do problema a resolver

- Analisar as variações na qualidade do ar em metrópole asiática através do comportamento dos poluentes particulados PM2.5 e PM10
- Variaveis a serem trabalhadas: Year, Month, PM2.5, PM10

## 2. Preparação dos datasets e exploração dos dados

In [1]:

```
# Importar as bibliotecas para fazer análise exploratória dos dados

import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline

import os
import glob
```

In [3]:

```
# Extrair o conjunto de datasets e concatená-los em 1 arquivo

path = r"C:\Users\Henrique.Min\Desktop\Temp\PRSA_Data" # Local onde se encontram os dataset
all_files = glob.glob(os.path.join(path,"*.csv"))      # Agrupamento dos datasets

df = pd.DataFrame()
list_ = []

for file_ in all_files:
    df = pd.read_csv(file_, index_col = None, header = 0)
    list_.append(df)

df = pd.concat(list_)

cols = ['No', 'year', 'month', 'day', 'hour', 'PM2.5', 'PM10', 'SO2', 'NO2', 'CO', 'O3',
        'TEMP', 'PRES', 'DEWP', 'RAIN', 'wd', 'WSPM', 'station']

df = df[cols]
df.head()
```

Out[3]:

| | No | year | month | day | hour | PM2.5 | PM10 | SO2 | NO2 | CO | O3 | TEMP | PRES | DEWP |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **0** | 1 | 2013 | 3 | 1 | 0 | 4.0 | 4.0 | 4.0 | 7.0 | 300.0 | 77.0 | -0.7 | 1023.0 | -18.8 |
| **1** | 2 | 2013 | 3 | 1 | 1 | 8.0 | 8.0 | 4.0 | 7.0 | 300.0 | 77.0 | -1.1 | 1023.2 | -18.2 |
| **2** | 3 | 2013 | 3 | 1 | 2 | 7.0 | 7.0 | 5.0 | 10.0 | 300.0 | 73.0 | -1.1 | 1023.5 | -18.2 |
| **3** | 4 | 2013 | 3 | 1 | 3 | 6.0 | 6.0 | 11.0 | 11.0 | 300.0 | 72.0 | -1.4 | 1024.5 | -19.4 |
| **4** | 5 | 2013 | 3 | 1 | 4 | 3.0 | 3.0 | 12.0 | 12.0 | 300.0 | 72.0 | -2.0 | 1025.2 | -19.5 |

In [4]:

```
# Cria uma cópia do dframe
df_copy = df.copy()
```

In [5]:

```
df_copy.head()
```

Out[5]:

| | No | year | month | day | hour | PM2.5 | PM10 | SO2 | NO2 | CO | O3 | TEMP | PRES | DEWP |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| **0** | 1 | 2013 | 3 | 1 | 0 | 4.0 | 4.0 | 4.0 | 7.0 | 300.0 | 77.0 | -0.7 | 1023.0 | -18.8 |
| **1** | 2 | 2013 | 3 | 1 | 1 | 8.0 | 8.0 | 4.0 | 7.0 | 300.0 | 77.0 | -1.1 | 1023.2 | -18.2 |
| **2** | 3 | 2013 | 3 | 1 | 2 | 7.0 | 7.0 | 5.0 | 10.0 | 300.0 | 73.0 | -1.1 | 1023.5 | -18.2 |
| **3** | 4 | 2013 | 3 | 1 | 3 | 6.0 | 6.0 | 11.0 | 11.0 | 300.0 | 72.0 | -1.4 | 1024.5 | -19.4 |
| **4** | 5 | 2013 | 3 | 1 | 4 | 3.0 | 3.0 | 12.0 | 12.0 | 300.0 | 72.0 | -2.0 | 1025.2 | -19.5 |

In [6]:

```
# Resumo do dataset por coluna: contagem, media, desvio padrão, vmin, vmax
df_copy.describe()
```

Out[6]:

| No | year | month | day | hour | PM2.5 | PM |
|---|---|---|---|---|---|---|
| 000000 | 420768.000000 | 420768.000000 | 420768.000000 | 420768.000000 | 412029.000000 | 414319.0000 |
| 500000 | 2014.662560 | 6.522930 | 15.729637 | 11.500000 | 79.793428 | 104.6026 |
| .116943 | 1.177198 | 3.448707 | 8.800102 | 6.922195 | 80.822391 | 91.7724 |
| 000000 | 2013.000000 | 1.000000 | 1.000000 | 0.000000 | 2.000000 | 2.0000 |
| 750000 | 2014.000000 | 4.000000 | 8.000000 | 5.750000 | 20.000000 | 36.0000 |
| 500000 | 2015.000000 | 7.000000 | 16.000000 | 11.500000 | 55.000000 | 82.0000 |
| 250000 | 2016.000000 | 10.000000 | 23.000000 | 17.250000 | 111.000000 | 145.0000 |
| 000000 | 2017.000000 | 12.000000 | 31.000000 | 23.000000 | 999.000000 | 999.0000 |

In [7]:

```
# Resumo de total de registros por coluna, tipo de dado, quantidade total de colunas, uso d
df_copy.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Int64Index: 420768 entries, 0 to 35063
Data columns (total 18 columns):
No          420768 non-null int64
year        420768 non-null int64
month       420768 non-null int64
day         420768 non-null int64
hour        420768 non-null int64
PM2.5       412029 non-null float64
PM10        414319 non-null float64
SO2         411747 non-null float64
NO2         408652 non-null float64
CO          400067 non-null float64
O3          407491 non-null float64
TEMP        420370 non-null float64
PRES        420375 non-null float64
DEWP        420365 non-null float64
RAIN        420378 non-null float64
wd          418946 non-null object
WSPM        420450 non-null float64
station     420768 non-null object
dtypes: float64(11), int64(5), object(2)
memory usage: 61.0+ MB
```

In [8]:

```
# Verificação de valores missing presentes por coluna
# Identificado valores missing de PM2.5 até WSPM
df_copy.isnull().sum()
```

Out[8]:

```
No             0
year           0
month          0
day            0
hour           0
PM2.5       8739
PM10        6449
SO2         9021
NO2        12116
CO         20701
O3         13277
TEMP         398
PRES         393
DEWP         403
RAIN         390
wd          1822
WSPM         318
station        0
dtype: int64
```

In [11]:

```
# Descricao resumida da coluna PM2.5
df_copy['PM2.5'].describe()
```

Out[11]:

```
count    412029.000000
mean         79.793428
std          80.822391
min           2.000000
25%          20.000000
50%          55.000000
75%         111.000000
max         999.000000
Name: PM2.5, dtype: float64
```

In [12]:

```
# Descricao resumida da coluna PM10
df_copy['PM10'].describe()
```

Out[12]:

```
count    414319.000000
mean        104.602618
std          91.772426
min           2.000000
25%          36.000000
50%          82.000000
75%         145.000000
max         999.000000
Name: PM10, dtype: float64
```

In [13]:

```
# Descricao resumida da coluna TEMP
df_copy['TEMP'].describe()
```

Out[13]:

```
count    420370.000000
mean         13.538976
std          11.436139
min         -19.900000
25%           3.100000
50%          14.500000
75%          23.300000
max          41.600000
Name: TEMP, dtype: float64
```

In [14]:

```
# Inserir valores missing para normalização de dados nas variáveis PM2.5 e PM10
df_copy['PM2.5'].fillna(df_copy['PM2.5'].median(), inplace = True)
df_copy['PM10'].fillna(df_copy['PM10'].median(), inplace = True)
```

In [15]:

```
# Verificando se valores missing foram preenchidos em PM2.5 e PM10
df_copy.isnull().sum()
```

Out[15]:

```
No             0
year           0
month          0
day            0
hour           0
PM2.5          0
PM10           0
SO2         9021
NO2        12116
CO         20701
O3         13277
TEMP         398
PRES         393
DEWP         403
RAIN         390
wd          1822
WSPM         318
station        0
dtype: int64
```

In [16]:

```
# Verificar se valores missing afetaram o resumo dos dados de PM2.5
# Valores missing aumentaram a contagem de registros,fez uma pequena alteração na média, de

df_copy['PM2.5'].describe()
```

Out[16]:

```
count    420768.000000
mean         79.278489
std          80.056799
min           2.000000
25%          21.000000
50%          55.000000
75%         109.000000
max         999.000000
Name: PM2.5, dtype: float64
```

In [17]:

```
# Verificar se valores missing afetaram o resumo dos dados de PM10
# Valores missing aumentaram a contagem de registros,fez uma pequena alteração na média, de

df_copy['PM10'].describe()
```

Out[17]:

```
count    420768.000000
mean        104.256193
std          91.108745
min           2.000000
25%          36.000000
50%          82.000000
75%         144.000000
max         999.000000
Name: PM10, dtype: float64
```

In [22]:

```
# Analiser histórico de emissões de PM2.5 e PM10 de todo o período do dataset
# 2014 foi o ano que apresentou maior nível de emissão de ambos os PMs
# PM2.5 variou de 50 a 60
df_year_PM25 = df_copy[['year', "PM2.5"]].groupby(['year']).median()
df_year_PM10 = df_copy[['year', 'PM10']].groupby(['year']).median()

fig, ax1 = plt.subplots(figsize=(12,2))
fig, ax2 = plt.subplots(figsize=(12,2))

ax1.plot(df_year_PM25, color = 'blue')
ax2.plot(df_year_PM10, color = 'red')

ax1.set_title('Mediana de PM2.5 por ano', fontsize = 15)
ax1.set_xlabel('Ano')
ax1.set_ylabel('Emissão de PM2.5')

ax2.set_title('Mediana de PM10 por ano', fontsize = 15)
ax2.set_xlabel('Ano')
ax2.set_ylabel('Emissão de PM10')

plt.show()
```

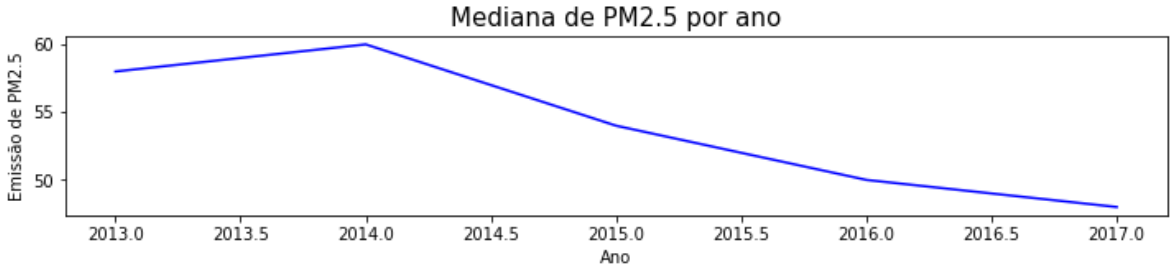


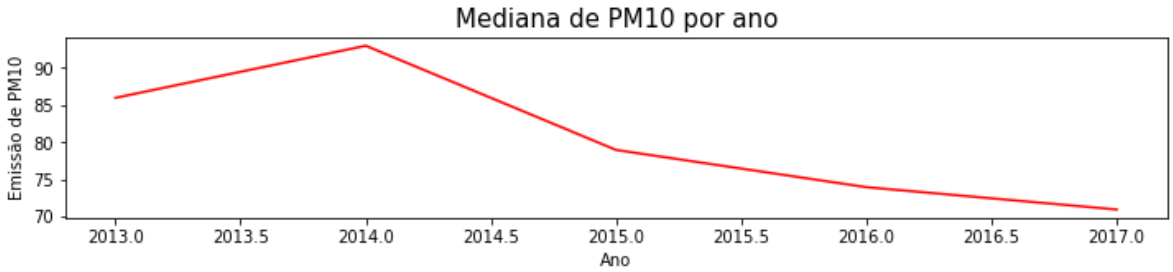


In [24]:

```
# Filtrar os anos de 2014 (ano de maior emissão) e 2016 (ano de menor emissão)
# Ano de 2017 apresenta apenas 2 meses, por isso não foi considerado para comparativo
df_2014 = df_copy[df_copy['year'] == 2014]
df_2016 = df_copy[df_copy['year'] == 2016]
```

In [30]:

```
# Analisar emissão de PM2.5 no ano de 2014 e 2016 por mês
df_2014_PM25 = df_2014[['month', 'PM2.5']].groupby(['month']).median()
fig, ax1 = plt.subplots(figsize = (12,2))
ax1.plot(df_2014_PM25, color = 'blue')
ax1.set_title('Mediana de PM2.5 por mês - 2014', fontsize = 15)
ax1.set_xlabel('Meses')
ax2.set_ylabel('PM2.5')


df_2016_PM25 = df_2016[['month', 'PM2.5']].groupby(['month']).median()
fig, ax2 = plt.subplots(figsize = (12,2))
ax2.plot(df_2016_PM25, color = 'red')
ax2.set_title('Mediana de PM2.5 por mês - 2016', fontsize = 15)
ax2.set_xlabel('Meses')
ax2.set_ylabel('PM2.5')

plt.show()
```

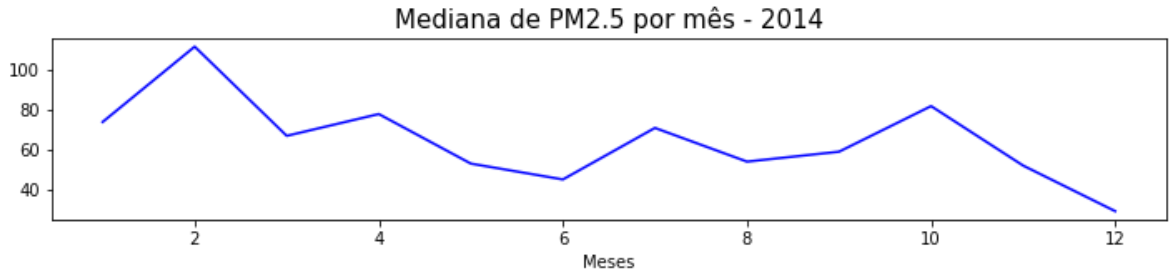


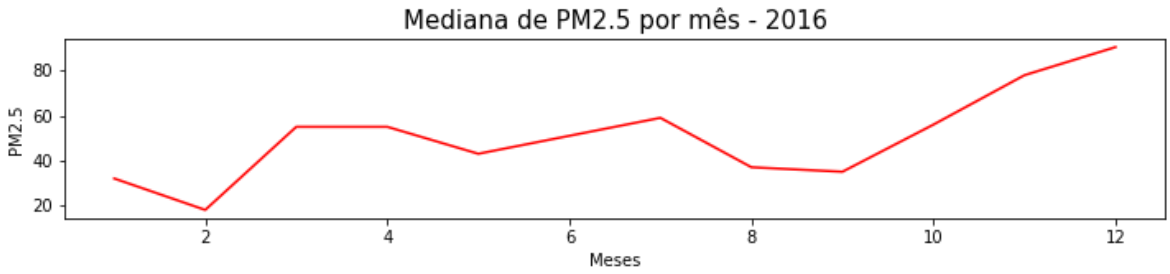

In [31]:

```
# Analisar emissão de PM10 no ano de 2014 e 2016 por mês
df_2014_PM10 = df_2014[['month','PM10']].groupby(['month']).median()
fig, ax1 = plt.subplots(figsize = (12,2))
ax1.plot(df_2014_PM10, color = 'blue')
ax1.set_title('Mediana de PM10 por mês - 2014')
ax1.set_xlabel('Mês')
ax1.set_ylabel('PM10')

df_2016_PM10 = df_2016[['month', 'PM10']].groupby(['month']).median()
fig, ax2 = plt.subplots(figsize =(12,2))
ax2.plot(df_2016_PM10, color = 'red')
ax2.set_title('Mediana de PM10 por mês - 2016')
ax2.set_xlabel('Mês')
ax2.set_ylabel('PM10')

plt.show()
```

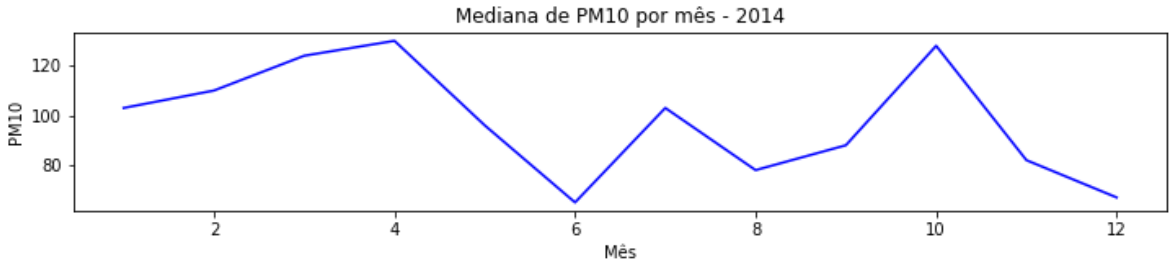


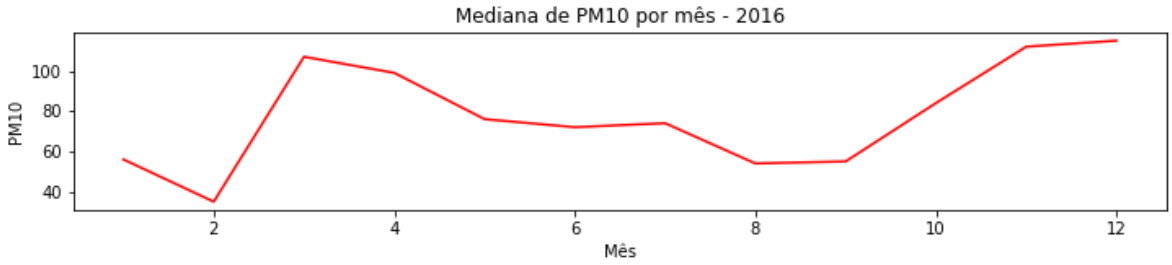

In [33]:

```
# Mapa de calor, identificando a correlação entre as variáveis
corr = df_copy.corr()
ax = sns.heatmap(corr, vmin = -1, vmax = 1, center = 0, cmap = sns.diverging_palette(10, 60

ax.set_xticklabels(ax.get_xticklabels(), rotation = 45, horizontalalignment = 'right');
```

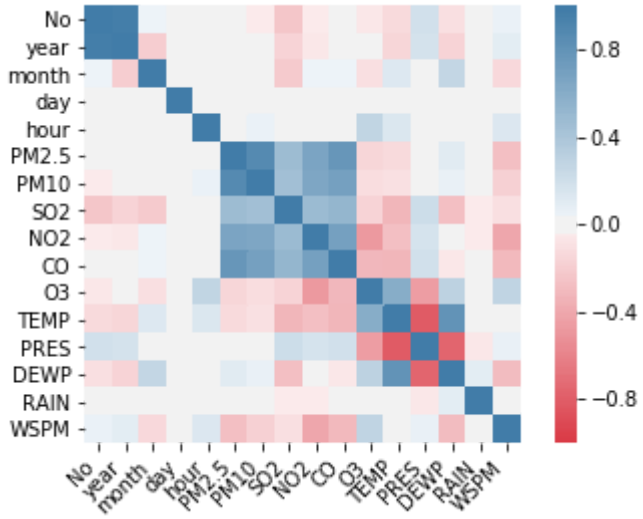


In [ ]:

```
# Comparativo de CO em 2014 e 2016 por mês
df_2014_co = df_2014[['month', 'CO']].groupby(['month']).median()
fig,ax1 = plt.subplots(figsize=(12,1.5))
ax1.plot(df_2014_co, color = 'blue')

ax1.set_title('Histórico CO - 2014')
ax1.set_xlabel('Meses')
ax1.set_ylabel('CO')

df_2016_co = df_2016[['month', 'CO']].groupby(['month']).median()
fig,ax1 = plt.subplots(figsize=(12,1.5))
ax1.plot(df_2016_co, color = 'red')

ax1.set_title('Histórico CO - 2016')
ax1.set_xlabel('Meses')
ax1.set_ylabel('CO')

plt.show()
```

## 3. Resultados

- Partículas PM2.5, PM10, SO2, NO2, CO apresentam correlação positiva.
- SO2, NO2, CO são gases tóxicos e tem grande parte de sua produção pela atividade industrial.
- Ano de 2014, maiores níveis de emissões de partículas foram no começo do ano.
- Já em 2016, maiores níveis de emossões de particulas foram no final do ano.